

R8: An Exploratory Lexical Framework for Approximating Cognitive Manipulation Risk in Text

(テキストにおける認知操作リスク近似のための探索的語彙フレームワーク)

斉藤隆博 (臨床心理学修士)
独立研究者

takahiro@saito-audit.com

ORCID: 0009-0005-9464-6260

GitHub: <https://github.com/takahiro-oss/r8-cognitive-risk>

ライセンス: CC BY 4.0 | 状態: プレプリント (査読前) | 日付: 2026 年 5 月 | バージョン: v1.8

Abstract (抄録)

R8 (Cognitive Risk Analyzer) は、理論的根拠を持つ 12 カテゴリにわたって日本語テキストの認知操作リスクを近似するための探索的語彙フレームワークを提案する。本論文で提示する主張は現在の実装が支持できる範囲に限定される。多カテゴリ採点アーキテクチャは、MMPI のような因子ベースの心理測定モデルから方法論的等価性ではなく概念的着想を得ている。

理論的枠組みは、日本の組織社会学 (Yamamoto, 1977; Nakane, 1967; Tobe et al., 1991) と西洋社会心理学 (Janis, 1972; Milgram, 1963; Kahneman, 2011) を統合し、これらの伝統を System 1 認知処理を標的とする言語シグナルの統合的検出システムとして操作化する。

本システムは単一の合成スコアである認知操作指数 (CMI) を産出する。217 件のコーパス (有効 CMI > 0 : 208 件) に対する初期校正では、標準検出モード (HIGH ≥ 41) において HIGH リスク二値分類の Precision 97.7% $\cdot$ Recall 35.2% $\cdot$ F1 51.8 が得られた。二モデル LLM パイロット注釈実験では著者の v0.7.1 human_label に対して Cohen's $\kappa = 0.231$ (Claude Sonnet 4.6) および $\kappa = 0.103$ (Gemini 2.5 Flash) が得られ、注釈基準が汎用言語モデルでは再現不可能な構造的読解を要することを確認した。独立した人間評定者が Phase 2 信頼性評価の基盤となる。コーパスおよびスコアリングデータの全体は CC BY 4.0 ライセンスのもと <https://github.com/takahiro-oss/r8-cognitive-risk> で公開されている。

1. Introduction (序論)

デジタル情報の急増により、正当なコミュニケーションと認知操作を識別する課題はより深刻になっている。この問題に対する既存のアプローチ——ファクトチェックシステム、ヘイトスピーチ検出、誤情報分類器など——は主としてコンテンツの真偽に焦点を当てている。しかし認知操作は、事実の虚偽性に先行する構造的レベルで機能する。メッセージは事実として正確でありながら、緊迫感・権威の偽装・感情的増幅・論理的誘導によって心理的脆弱性を同時に利用することができる。

この操作の構造的側面は、組織研究において定性的に検討されてきた。Tobe et al. (1991) は、第二次世界大戦における日本の組織崩壊に先行した認知パターンを特定した——否定的情報の抑圧、権威

への過度の依存、感情駆動による意思決定がそれである。構造的に等価な現象が西洋の組織文脈においても記録されている。Janis (1972) はケネディ政権によるビッグス湾侵攻計画の承認を分析し、作戦の前提となった6つの重要な想定——キューバ空軍を上陸前に無力化できるという信念や、侵攻が自発的な民衆蜂起を引き起こすという想定を含む——が、反証となる情報が利用可能であったにもかかわらず批判的検討なしに採用されたことを示した (pp. 32-46)。Janis はこの失敗様式を「集団浅慮 (Groupthink)」と命名した：集団内圧力から生じる精神的効率性・現実検証・道徳的判断の劣化である。これらのパターンはいずれの文化的文脈にも固有のものではなく、企業・政治・メディアの文脈において繰り返し現れる。

R8 (Cognitive Risk Analyzer ; 「R8」 という名称は初回公開年である令和8年に由来する) は、この定性的伝統の語彙的拡張を提案する。本システムは心理測定学および臨床心理学のフレームワークから導出された12のリスクカテゴリにわたって機能し、単一の合成スコアであるCMIを産出する。本論文はR8を、検証済みの測定ツールではなく探索的ベースライン計測器として明示的に位置づける。

並行する問題が計算言語学の機械読解研究からも提起されている。Arai (2018) は、AIシステムが真の意味理解に到達することなく統計的パターンマッチングによってテキストを処理することを示した。この知見はR8を支持するものではなく、むしろ警告として機能する——表層的なパターンマッチングは、AIによるものであれ語彙ツールによるものであれ、意味の捕捉に系統的に失敗するリスクがあることを示しているためである。R8も同じ制約のもとで動作する。

本論文は、オープンソースの語彙監査フレームワークとしてのR8の理論的基盤・実装・初期校正を記述する。表層的語彙分析は文脈の感度に限界があるものの、認知リスク近似のための再現可能かつ透明なベースラインを提供する——より深い意味論的分析を置き換えるのではなく補完するものとして。

R8はテキスト中の操作親和的シグナルの語彙密度を近似するスクリーニングツールとして設計されている。現時点では、本システムは著者の意図を判定することも、検出された語彙が読者に与える認知的効果を実証的に示すこともできない。これらの制約は表層的語彙分析の構造的限界 (Section 5 で詳述) から生じる。したがってCMIスコアは操作的意図の確定的判断としてではなく、より精密な精査を要するテキストを特定するための初期フラグとして機能する。

これらの制約を認めたとうえで、R8の有用性は三つの特性に依拠する。第一に、透明性と再現性：ルールベースの辞書照合アーキテクチャにより、すべてのスコアの根拠が完全に説明可能かつ手動で検証可能である。第二に、スケーラビリティ：大量のテキストを固定された基準のセットに対して一貫して処理できる。第三に、補完的機能：人間の判断と文脈情報と組み合わせることで、R8は批判的評価を置き換えるのではなく診断的補助ツールとして機能する。

将来の開発方向性としては、構造的パターン検出の実装 (Phase 2 第二層アーキテクチャ)、対照コーパス構築による偽陰性検出、および音声・映像コンテンツを含むマルチモーダル分析への拡張が挙げられる。マルチモーダル拡張は、R8パイプラインの前段に音声テキスト変換ステージ (Whisper など) を置くことで技術的に実現可能である。これらの開発は意図レベルの評価に近づくための研究優先事項として位置づけられ、Section 7 で詳述する。

操作シグナルに対する個人レベルの防衛の認知的困難さは十分に記録されている。Cialdini (1984) は権威シグナルに対する二問検証手順——「この人物は真に専門家か」「この専門家はどれほど信頼に値するか」——を提案しつつ、専門家が自身の信用性の外観を演出するために軽微な不利な情報を戦略的に開示し、その後は全情報が無批判に受容される可能性を指摘した (pp. 371-72)。同様に希少性に基づく圧力について、Cialdini は希少性シグナルが生成する感情的覚醒が自己防衛に必要な熟慮的能力を能動的に損なうと述べる (p. 425)。これらの観察はR8が対象とする操作親和的シグナルのより広範なクラス全体に一般化できる——操作を有効にする認知的条件は、まさしく個人防衛を不確実にする条件でもある。R8はこの構造的ギャップに対処するために、事前インタラクション・テキストスクリーニングを提供するよう設計されている。これは読者のリアルタイム熟慮能力に依存しない機能である。

2. Theoretical Background (理論的背景)

R8 の理論的枠組みは、これまで独立して発展してきた研究伝統を、統合的構成概念——System 1 認知処理を標的とする言語シグナル (Kahneman, 2011) ——のもとに統合する。このフレーミングは R8 を単なるテキスト分析ツールとしてではなく、認知操作の研究における学際的収束の操作化として位置づける。

本枠組みは六つの研究領域に依拠する。日本の組織社会学と文化心理学 (Yamamoto, 1977; Nakane, 1967; Tobe et al., 1991) は、暗黙的な認知的強制が機能する構造的条件を確立する。西洋社会心理学 (Janis, 1972; Milgram, 1963, 1974; Cialdini, 1984) は構造的に等価な現象を独立して特定し、文化横断的な根拠を提供する。認知心理学 (Kahneman, 2011) はこれらの観察を統合する処理アーキテクチャを提供する：操作親和的な言語シグナルは System 1 応答——高速・自動的・無努力——を活性化することで、熟慮的な System 2 評価が作動する前に機能する。操作の臨床心理学は複数カテゴリの概念的根拠を支え、精神分析的伝統 (Symington, 1993) は閾値下の依存誘導メカニズムについての記録を提供する。心理測定学的方法論 (Hathaway & McKinley, 1943) は多カテゴリ合成スコアリングのアーキテクチャモデルを提供する。計算言語学 (Da San Martino et al., 2019; Pennebaker et al., 2015) は R8 を既存の検出アプローチの中に位置づける。

この統合の新規な貢献は、これらの伝統に共通する機能的メカニズムの特定にある：各伝統は、言語構造が熟慮の評価を迂回する異なる経路を記録している。R8 はこのメカニズムを語彙密度近似として操作化する。以下のセクションでは、この理論的基盤の各構成要素を順次展開する。

2.1 制度的失敗から認知操作へ——「失敗の本質」フレームワーク

組織における認知的失敗の構造的分析は、日本の組織研究において定性的に検討されてきた。Tobe et al. (1991) は第二次世界大戦期の日本軍における組織崩壊の繰り返しパターンを特定した——それらのパターンは歴史的文脈を超えて、企業・政治・メディアの各環境において繰り返し現れるものである。

Tobe et al. が特定した四つの構造的パターンが R8 の設計に直接関係する。第一に、意思決定は客観的状況評価ではなく主観的な希望の思考に支配されていた——このパターンを R8 は EmotionalRisk (感情誘導リスク) として操作化する。第二に、論理的論拠は階層的権威と面目保持行動によって系統的に置き換えられた——これは R8 の AuthorityRisk (権威リスク) および LogicalRisk (論理リスク) カテゴリに対応する。第三に、組織は支配的な前提と矛盾するデータを抑圧し、否定的情報を一貫して取り込むことを拒んだ——このパターンは R8 の DisclaimerExploit (免責悪用) および AnonymousAuthority (匿名権威) スコアを通じて検出可能である。第四に、そして最も重要なことに、組織的意思決定は明示的なルールではなく暗黙の大氣的合意によって支配されていた。

これら四つのパターンが文化的・歴史的に異なる組織文脈において繰り返し現れること——西洋社会心理学 (Janis, 1972) と認知心理学 (Kahneman, 2011) においても独立して記録されている——は、Section 2.4 および Section 2.5 で展開する学際的基盤を提供する。

2.2 「空気」と縦社会——認知的強制の構造的基盤

この暗黙の大氣的合意は、山本 (1977) によって「空気」として理論化された——文字通り「air」——明示的な論拠のレベル以下で機能しながら、形式的な推論よりも強い力で集団的結果を決定する社会的圧力の形態である。空気は、明示的な正当化を必要とせずに合理的な異論を麻痺させる、論理外の強制力として機能する。

空気を支える構造的基盤は、中根 (1967) の日本的縦社会 (タテ社会) 分析において特定されている。このフレームワークでは、情報の信頼性はその内容ではなく情報源の階層的位置によって決定される。

真実は事実上、推論によって導き出されるのではなく地位によって割り当てられる。R8 はその疑似権威 (False Authority) および論理的誘導 (Logical Misdirection) カテゴリを通じて、この構造的ダイナミクスの代理指標を操作化する。この縦社会構造はさらに、内集団 (「うち」) と外集団 (「よそ」) の間に鋭い認知的境界を生成し、日本の組織的テキストにおいて EnemyFrame の言語シグナルが出現する社会的基盤を構成する (Nakane, 1967, pp. 46–47)。

山本は日本の戦時海軍指導部の事例を通じてこの力の強度を例証する：統計データ・分析報告書・形式的論理論拠を有する専門家たちが、自分たちが集団的に支持不可能と認識していた作戦をそれでも実行し、その後なぜそうしたのかについて合理的な説明を自ら行うことができなかった (Yamamoto, 1977, pp. 19–20)。この事例は R8 の理論的根拠にとって重要な意味を持つ：認知的失敗を生み出すのは証拠や推論能力の欠如ではなく、その両者が大氣的強制によって置き換えられることである。統計的分析・文書的証拠・論理的論拠は単に無視されるのではなく——機能的に無効化される。

山本はさらに、空気が生成されるメカニズムを特定する：それは自然発生的な文化現象としてではなく、意図的なテキスト構築の産物として。山本は明治期の西南戦争に関する新聞報道の分析において、再現可能な操作パターンを記録している——対立勢力を野蛮な侵略者の集団として描写する記事を系統的に掲載し、正当な権威の神聖化された表象——慈悲深い秩序の体現——と並置させるというパターンである (pp. 49)。この二項対立的構築——悪魔化された敵対勢力対神聖化された権威——は、合理的評価が作動する前に読者の感情の方向づけを固定する機能を果たす。山本は、そのような報道の捏造的性質は注意深い読者には検出可能であったにもかかわらず、大氣的効果はそれに関わらず達成されたと観察する (pp. 24, 49)。

山本の核心的知見——大氣的強制は自然発生的な文化現象ではなく意図的なテキスト構築の再現可能な産物である——は日本の組織的文脈を超えており、CMI 検出に直接関連する文化横断的適用可能性を持つ操作メカニズムを特定するものである。

2.3 認知的依存と System 1 脆弱性

操作に対する個人の脆弱性は、Kahneman (2011) が記述する認知アーキテクチャに根拠を持つ。System 1 思考——高速・自動的・無努力——は認知的デフォルトとして機能し、熟慮的評価なしに入力情報を処理する。System 1 処理に主として依存する個人は、緊迫感シグナルと免責悪用を通じた操作に対して脆弱であり——自律的批判的判断の活性化を妨げる可能性のある受動的受容の状態に置かれ続ける。この依存性は個人的な欠陥ではなく人間認知の構造的特性である：System 1 はデフォルトモードであり、熟慮的な System 2 評価を作動させるには能動的な努力を要する。

R8 は比喩的に「認知的防波堤」(Cognitive Breakwater) として記述される：その意図は、読者を熟慮ではなく認知的依存へと傾かせる可能性のある言語パターンを特定することにある。CMI は操作の直接的測定値としてではなく、そのような圧力と関連する言語シグナルの密度の近似値として定義される。

2.4 「空気」から CMI へ——暗黙的強制の語彙的近似

2.4.1 文化横断的収束

Tobe et al. (1991)、山本 (1977)、中根 (1967) が記述した構造的ダイナミクスは、日本に文化的に固有のものではない。西洋社会心理学は独立して、構造的に類似した現象を特定している。

Janis (1972) は「集団浅慮 (Groupthink)」という語のもとで、西洋の組織的文脈における類似の大氣的合意ダイナミクスを記録した。Milgram (1963) の服従実験は、権威への服従という文化横断的傾向を実証した。Kahneman (2011) はこれらの観察を統合する認知アーキテクチャを提供した：System 1 思考——高速・自動的・無努力——は操作的テキストが利用する可能性のある認知的デフォルトである。R8 の CMI は、テキスト中の System 1 圧力シグナルの集合的密度の近似値として解釈できる。

2.5 心理測定学的基盤

R8 の多カテゴリ採点構造は、共通のアーキテクチャ的論理を持つ確立した心理測定学的測定器から概念的着想を得ている：定性的に観察された心理的現象が複数の個別指標として操作化され、重み付け合成によって合成スコアへと集約される。

ミネソタ多面的人格目録（MMPI; Hathaway & McKinley, 1943）はこの構造を体現している。R8 はこのアーキテクチャ的論理をテキストの認知リスクに適用する：12 のリスクカテゴリは臨床尺度に類比的に機能し、それぞれが異なる言語的次元を捕捉する；CMI は重み付けされた合成値を表す。この着想は概念レベルのものに留まることを明示的に認めている。

2.6 計算言語学的アプローチとの関係

テキストにおける認知操作およびプロパガンダの計算的検出は、複数の相補的な研究伝統によって取り組まれてきた。

Da San Martino et al. (2019) は、ニュース記事においてフラグメントレベルで 18 の修辞技法を特定する精細なプロパガンダ検出フレームワークを提案した。彼らの分類システムは R8 の 12 カテゴリアーキテクチャと概念的な重複を持つが、実装アプローチは実質的に異なる：彼らのニューラル系列ラベリングモデルはフラグメントレベルの注釈を実現するのに対し、R8 は文書レベルの辞書ベース語彙密度によって機能する。解釈可能性のトレードオフは明示的である：R8 はカバレッジを犠牲にして監査可能性を優先する。

MentalManip データセット（Wang et al., ACL 2024）は会話テキストにおける操作検出のベンチマークを提供し、大規模言語モデルが操作判断タスクにおいて約 65% の分類精度を達成することを報告している。この数値は R8 の位置づけにとって注目に値する：最先端の LLM ベースアプローチが会話的操作において 65% を達成するならば、ルールベースシステムの解釈可能性の優位性は、説明可能な出力を必要とするステークホルダーが存在する特化した展開文脈においてその低いカバレッジを正当化しうる。

Pennebaker et al. (2015) の LIWC フレームワークは、語彙選択パターンが測定可能な心理的シグナルを担うことを確立し、密度ベースの採点アプローチに対して心理言語学的根拠を提供した。R8 はこのアーキテクチャ的論理を共有しつつ、一般的な心理的次元ではなく臨床心理学と組織行動論から導出された操作特異的カテゴリに適用する。

R8 はこれらのアプローチと三点において異なる。第一に、現在の実装スコープ：日本語テキストを対象としているが、これは理論的境界ではなく初期展開文脈を反映したものである。基盤となる理論的枠組みは文化横断的な認知・社会心理学（Kahneman, 2011; Janis, 1972; Milgram, 1963）に依拠しており、他言語への拡張は明示的な研究方向として位置づけられている（Section 7）。第二に、アーキテクチャ的選択：予測的カバレッジよりも解釈可能性を優先し、ニューラルではなく辞書ベースを採用する。第三に、理論的統合：日本の組織心理学（Tobe et al., 1991; Yamamoto, 1977; Nakane, 1967）と西洋社会心理学（Janis, 1972; Milgram, 1963; Kahneman, 2011）の文化横断的収束からの明示的な導出。

さらに二つの研究群が R8 の対象とする操作パターンに対する直接的な実証的根拠を提供する。Ross (2014) はカルト特性化の三つの構造的基準——絶対的権威・強制的説得技法・搾取的危害——を特定し、操作が物理的共在なしにテキストのみを通じて機能するオンラインカルトダイナミクスの出現を記録した。この観察はデジタルテキストを自己完結した操作媒体として捉える R8 の焦点に根拠を与える。Ben-Ghiat (2020) は歴史的・現代的文脈にわたる権威主義的政治指導者の修辞的戦略を分析し、繰り返し現れる操作パターンを特定した：聴衆の事実に基づく判断能力を圧倒する持続的偽情報キャンペーン（R8 の PropagandaRisk および EnemyFrame カテゴリに対応）、熟慮的評価を迂回する権威シグナル（AuthorityRisk）、合理的処理に先行して脅威反応を活性化させる恐怖ベースの動員（FearRisk および AbsolutistWords）。カルトコミュニケーション（Ross, 2014）と権威主義的政治修辞（Ben-Ghiat, 2020）を同一検出フレームワーク内で並行的に操作化することは、較正コーパスで代表されている組織的・商

業的・精神的・政治的ジャンルにわたる R8 のクロスドメイン適用可能性の主張を支持する。

エコーチェンバーとフィルターバブルに関する研究 (Sunstein, 2017) は操作的コンテンツが聴衆に到達する情報環境アーキテクチャを扱うが、これらのフレームワークは R8 とは異なる分析単位で機能する。R8 は個々のテキスト内に埋め込まれた言語シグナルを対象とし、それらのテキストが遭遇する分散的文脈とは独立している。この区別が本研究の主張の境界を画定する。

2.7 期待価値理論と読者目標の機能的操作

Eccles and Wigfield (2002) は期待価値理論 (Expectancy-Value Theory、以下 EVT) を、二つの心理的構成概念——個人の成功期待と特定の課題に割り当てられる主観的価値——を通じて達成行動を説明するフレームワークとして提案した。主観的価値はさらに、達成価値 (成功することの個人的重要性)・有用価値 (将来目標への手段的関連性)・内発的価値 (課題から得られる享楽)、およびコスト (必要とされる心理的・物質的犠牲) に分解される。

EVT は個人が自律的に動機的信念を形成する方法を記述するために教育心理学において発展した。本研究は操作的テキストにおけるこのフレームワークの構造的転倒を特定する：自律的評価から生じるのではなく、EVT 変数は語彙的手段によって外部から水増し・隠蔽・捏造される。有用価値は恐怖と緊迫感シグナルを通じて増幅される；達成価値は権威と排他性フレーミングを通じて引き上げられる；成功期待は検証不可能な統計的主張を通じて製造される；そしてコストは系統的に隠蔽されるか成長の証拠として再定義される。

R8 の 12 のリスクカテゴリは EVT 変数操作の理論的に動機づけられた代理指標として解釈できる。EmotionalRisk と FearRisk は理論的に有用価値の水増しと整合し；AuthorityRisk と PropagandaRisk は達成価値の標的化と；LogicalRisk と NakedNumber は期待の捏造と；DisclaimerExploit と AbsolutistWords はコスト隠蔽と整合する。Phase 1 較正で観察されたカテゴリベクトルプロファイル——特に HIGH 分類テキストにおける EnemyFrame・PropagandaRisk・FearRisk の同時活性化、およびカリスマ的起業家テキストにおける LogicalRisk 1.0 パターン——はこの理論的マッピングと方向的に一致するが、EVT 構成概念に対する正式な検証は本研究の範囲を超えた独立した測定機器を必要とする。このマッピングは CMI スコアが EVT 構成概念を直接測定するという主張ではなく、Phase 2 操作化の理論的基盤として提案されるものである。決定的に、内発的価値操作——真正な関与を模擬するための肯定的に価値づけられた語彙 (慈悲・感謝・光) の使用——は現在の語彙アーキテクチャの検出スコープから系統的に漏れ出し、Section 5.8 で記録された偽陰性の主要な発生源を構成する。

このマッピングは EVT 変数操作が意図的な著者設計を反映することを意味しない。Section 5.7 で記録されているように、R8 は EVT 変数操作として機能する語彙パターン——有用価値の水増し・コストの隠蔽・期待の捏造——を、そのような操作が意図的戦略を反映するか習慣的コミュニケーションパターンを反映するかとは独立して検出する。両者の区別は語彙的証拠のみによっては解決できない。

EVT の動機的アーキテクチャと R8 の経験的に導出されたカテゴリ構造の間の収束は独立した分析的経路を通じて到達されたものであり、R8 の設計の理論的一貫性に対する概念的支持を提供する。この関係は R8 が EVT 構成概念を直接操作化するという主張としてではなく、構造的対応として提示される。

EVT 変数操作の根底にある動機的基盤は帰属欲求理論によってさらに照らし出される。Baumeister and Leary (1995) は帰属欲求——安定した肯定的な対人関係を形成・維持すること——が認知・感情・行動に広汎な影響を持つ根本的な人間動機を構成すると提案した。操作的テキストはこの欲求を、内集団包摂と外集団排除の連続的構築を通じて系統的に利用する：敵対フレーミングと排他性シグナルを導入する前に類似性と共有アイデンティティを確立する (Section 3.3、EnemyFrame および PropagandaRisk 参照)。この連続的利用は EVT カテゴリの達成価値操作——特定のコミュニティへの帰属が個人的に不可欠であるという製造された感覚——と構造的に対応する。R8 の AuthorityRisk・EnemyFrame・EmotionalRisk カテゴリはこの動機的標的化の部分的検出代理として機能するが、利用パターンの連続的構造は語彙密度採点のスコープ外にあり、Phase 2 設計ターゲットとして特定されて

いる (Section 7.2)。

関連するメカニズムが心理的リアクタンスを通じて機能する。Brehm (1966) は行動的自由への知覚された脅威が自由を回復する動機的圧力を生成することを実証した——不作為を機会損失としてフレーミングする希少性シグナルによって利用されうる反応である。操作的テキストにおいて、希少性シグナル (期間限定オファー・数量制限・排他的アクセスフレーミング) はリアクタンススペースの接近動機を引き起こし、熟慮の評価を上書きする。Brock (1968) の商品理論はこのダイナミクスを形式化する：物体は入手可能性が低下するにつれてより望ましくなり、この効果は物質的財から情報やアイデアにまで拡張される。Brock はさらに、情報へのアクセス自体が制限される場合に情報の説得力が増すことを実証した——コンテンツと情報源の両方が排他的にフレーミングされる場合に増幅される効果である。これらのメカニズムは R8 の FearRisk および ClickbaitRisk カテゴリの基盤をなし、Phase 2 開発のために提案された ScarcityRisk カテゴリの理論的根拠を提供する (Section 7.4)。

Cialdini (1984) はこれらのメカニズムを行動的フレームワークの中に統合する。権威シグナル——肩書・資格・機関所属——は Kahneman (2011) がデフォルト認知モードとして特定するのと同じ System 1 経路を通じて自動的服従反応を引き起こす。決定的に、Cialdini はこの反応を引き起こすのは情報源の実際の権威ではなく、実質的な資格なしにも服従を引き出すことが実験的に実証されたシンボル——肩書・服装・自動車——によって伝えられる知覚された権威であることを示す (p. 371)。テレビドラマで大統領を演じた俳優が真の政治的権威として扱われ、実際の大統領政策について質問された——実際の専門知識によって生成されたものと同一の服従反応である (p. 349)。この知見は R8 の設計根拠に直接関連する：R8 の AnonymousAuthority および AuthorityRisk カテゴリは権威の言語的シンボル——肩書・推薦・機関的言及——を検出するが、それは情報源の実際の権威ではなく、読者において System 1 活性化トリガーとして機能するのはこれらのシンボルであるためである。

これらの理論的伝統を通じて、個人認知レベルにおける共通の機能的パターンが浮かび上がる：それぞれが、外部から提示されたシグナル——権威・希少性・感情的訴求・価値の水増しとしてフレーミングされたものを問わず——が System 1 処理 (Kahneman, 2011) を作動させ、熟慮的評価の発動確率を低下させる異なるメカニズムを特定している。R8 の 12 カテゴリは、日本語テキストにおいてこれらの経路を通じて機能するシグナルの語彙密度を近似するように設計されている。

3. 方法論

3.1 システムアーキテクチャ

R8 は三つの逐次的プロセスのパイプラインとして動作する：テキスト取得・語彙分析・スコア集計。入力ソースにはプレーンテキストファイル・PDF ドキュメント・WebURL が含まれる。取得されたすべてのテキストはソースの種類にかかわらず統一された分析関数に渡される。

3.2 テキスト正規化 (Phase 1)

分析に先立ち、すべての入力テキストは表記揺れを低減するための正規化を受ける。正規化パイプラインは Unicode NFKC 正規化を適用し、続いて Unicode コードポイントマッピング (U+30A1–U+30F3、オフセット-96) によるカタカナからひらがなへの変換を行う。

3.3 12 リスクカテゴリの操作的定義

12 カテゴリは認知心理学・社会心理学・組織行動論・修辞分析フレームワークから導出されている。各カテゴリは語彙密度測定として操作化される：照合された辞書用語の数をテキスト長（100 文字あたり）で除したものの。Table 2 は各カテゴリの検出対象と主要な理論的根拠を示す。注釈基準と意思決定ルールを含む完全な操作的定義は、<https://github.com/takahiro-oss/r8-cognitive-risk> の公開注釈基準（v0.8）に記録されている。¹

Table 2. 12 リスクカテゴリの操作的定義

カテゴリ	検出対象	理論的根拠
EmotionalRisk	感情の覚醒語彙	Kahneman (2011); Cialdini (1984)
FearRisk	恐怖・緊迫感誘導	Kahneman (2011); Cialdini (1984)
AuthorityRisk	正当な権威の利用	Milgram (1963); Cialdini (1984)
AnonymousAuthority	検証不可能な権威引用	Nakane (1967); Cialdini (1984)
LogicalRisk	論理的誘導	Janis (1972); Tobe et al. (1991)
StatisticalRisk	偽の・文脈を外れた数値化	Kahneman (2011)
HypeRisk	誇張と根拠のない最上級表現	Kahneman (2011); Cialdini (1984)
ClickbaitRisk	好奇心ギャップと注意捕捉フレーミング	Brehm (1966); Brock (1968)
PropagandaRisk	内外集団フレーミングと偽情報パターン	Janis (1972); Ben-Ghiat (2020)
EnemyFrame	明示的な外集団指定	Nakane (1967); Janis (1972)
AbsolutistWords	絶対的・強制的命令語	Ross (2014)
DisclaimerExploit	責任回避・同意迂回言語	Kahneman (2011); Cialdini (1984)

実装スコープに関する注記：Table 2 に示した 12 の理論的カテゴリに加えて、実装済みシステムには本論文の理論的枠組みに含まれない三つの補足的指標が存在する。補助指標のひとつ Naked Number は、出典のない具体的な数量（例：「X 倍」「X 円」の無引用主張）を検出し、12 の主要カテゴリとの組み合わせ解釈のために設計された二値シグナルとして機能する——独立した検出対象としてではなく；CMI への寄与重みは 0.06 である。二つの周辺指標は応用展開文脈に対応する：Sexual Induction Risk（重み 0.04、CMI に含む）および Beauty/Diet Hype Risk（重み 0.00、参照専用、CMI から除外）。Beauty/Diet Hype Risk は商業文脈において女性読者を対象に多用されるジェンダー標的型操作パターン（美容・減量・恋愛マーケティングコンテンツ）を捕捉するために実装されている；重み 0.00 は当該シグナルが重要でないという判断ではなく現段階のコーパス較正データの不足を反映しており、ジェンダー標的型商業コンテンツのより大きなサンプルを含む拡張コーパスでの将来的な較正によって非ゼロの重みへの再割り当てが正当化される可能性がある。これらの補足的指標は応用展開文脈のための実装拡張を表す。

¹v0.8 注釈基準は v0.7.1 の構造的改訂版であり、すべての判断条件（H-1 から L-3）は v0.7.1 と逐語的に同一である。本論文で報告する Phase 1 較正指標（Precision・Recall・Cohen's κ ）は v0.7.1 のもとで取得された。Phase 2 評定者間信頼性評価は v0.8 のもとで実施される。

3.4 二層権威検出

AuthorityRisk は疑似権威と正当な権威参照を区別する二層検出アーキテクチャを採用する。疑似権威マーカーはリスク指標として直接採点される。正当な権威マーカーは条件付きで採点される：そのリスク寄与は同時発生する HypeRisk 密度によって変調される。

3.5 採点アルゴリズム

CMI は次式に基づく正規化されたカテゴリスコアの重み付き合計として算出される：

$$CMI = \sum_{i=1}^n w_i \cdot D_i$$

ここで D_i はカテゴリ i の正規化語彙密度（100 文字あたりの照合用語数）、 w_i は対応するカテゴリ重み、 $n = 12$ は理論カテゴリ数（補足的指標を別途追加）を表す。重みは採点対象全体にわたり $\sum w_i = 1$ を満たす。カテゴリ重みは各操作次元の総合認知リスクへの相対的寄与を反映し、理論的推論と小規模パイロットコーパスでの反復的実証較正を通じて導出された。StatisticalRisk は最高重み（0.16）を持ち、偽の数値化の理論的操作効力を反映する。CMI は 0 から 100 の範囲をとる。

リスク分類の閾値水準は二つのモードで機能する。標準モード（デフォルト）は HIGH : $CMI \geq 41$ 、MEDIUM : $35 \leq CMI < 41$ 、LOW : $CMI < 35$ を設定し、スクリーニング感度を最適化する（Precision = 97.7%、Recall = 35.2%、F1 = 51.8）。高精度モードは HIGH : $CMI \geq 60$ 、MEDIUM : $35 \leq CMI < 60$ 、LOW : $CMI < 35$ を設定し、特異度を最適化する（Precision = 100.0%、Recall = 4.9%）。閾値は言語モデル推論における温度パラメータに類比的なチューニング可能なパラメータとして扱われる：適切な設定は展開文脈と偽陽性対偽陰性の相対的コストに依存する。本論文で報告されるすべてのコーパス統計は標準モード（HIGH ≥ 41 ）を使用する。

3.6 実装と AI 開示

R8 は Python 3.x で二つのモジュールとして実装されている：r8.py(単一文書分析)および mass_audit.py (バッチ処理)。本システムは機械学習インフラを必要とせず、辞書照合と正規表現マッチングのみによって動作する。すべてのソースコードは CC BY 4.0 のもと <https://github.com/takahiro-oss/r8-cognitive-risk> で公開されている。

R8 の開発は大規模言語モデル（Claude、Anthropic；Gemini、Google）の支援のもとで実施された。AI 支援が提供された内容：コード開発と最適化、日本語と英語間の翻訳、本原稿のセクションの草稿支援、および文献の要約と統合。

以下の決定と分析は著者のみによって実施された：理論的枠組みの設計、12 のリスクカテゴリの選択と操作化、日本語語彙辞書の構築、カテゴリ重みの較正、すべての実質的な研究方向と解釈的選択、較正コーパスの手動注釈、および限界と含意の批判的評価。

著者は臨床心理学修士（愛知学院大学、2012 年）を有し、日本の教育現場での約 20 年の直接的経験を持つ。

3.7 LLM パイロット注釈実験

独立した人間評定者による Phase 2 の正式な信頼性評価に先立ち、v0.7.1 注釈基準の構造的難易度を評価し、モデル間の注釈挙動を比較するため、大規模言語モデルパイロット注釈実験を実施した。

二つのモデルを使用した：Claude Sonnet 4.6 (Anthropic、2026 年) を主要アノテーターとして、Gemini 2.5 Flash (Google、2026 年) をモデル間比較のための副次的アノテーターとして使用した。両モデルに同一の v0.7.1 注釈プロンプトを投与した。このプロンプトは、送信者の身元や組織的所属といったテキスト外情報を参照せず、テキストの言語的構造のみに基づいて HIGH・MEDIUM・LOW の三レベルのいずれかを付与するよう指示するものである。注釈プロンプトは v0.7.1 注釈基準文書から直接導出されており、<https://github.com/takahiro-oss/r8-cognitive-risk> で公開されている。著者の意図がテキスト内の言語的証拠のみでは判断できない場合のために Intent-Unresolved オプションが設けられたが、いずれのモデルもこのラベルをゼロ文書に付与した。

注釈安定性を評価するため、各モデルで 5 回の独立した反復実験を実施した。Claude はフルコーパス (実行あたり $n = 217$) で Run 1-5 を実施した。Gemini はコーパス確定前に初回実行が行われたため分析から除外し；Run 2-6 (実行あたり $n = 213$) が 5 回の有効な反復実験を構成する。²

各 LLM アノテーターと著者の v0.7.1 human_label 付与との評定者間信頼性を、標準式を用いて Cohen's κ として算出した：

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

ここで P_o は観察された一致割合を、 P_e は三ラベルカテゴリ (HIGH・MEDIUM・LOW) 全体で算出された偶然期待される一致割合を表す。

3.8 定性的不一致分析

LLM 注釈と human_label 付与の間の不一致の構造的原因を調査するため、不一致事例の系統的にサンプリングされたサブセットに対して定性的分析を実施した。

分析は、v0.7.1 のもとで著者が MEDIUM を付与したが一方または両方の LLM アノテーターが HIGH を付与した文書を対象とする MEDIUM→HIGH 不一致方向を標的とした。この方向は、精査を要する文書がエスカレートされない最も操作上重要な失敗モードを表すため選択され、Section 5.8 で文書化された偽陰性限界に直接関連するためでもある。

サンプリングプールは、両 LLM アノテーターにわたり MEDIUM→HIGH 不一致基準を満たすすべての文書から構成された (Gemini 2.5 Flash : $n = 57$; Claude Sonnet 4.6 : $n = 17$)。主観的な事例選択を避けるためにプログラマ的に実装された三優先度層化サンプリング手順を用いて 25 文書を選択した。優先度 A は両 LLM アノテーターが独立して HIGH を付与した 12 文書 (両モデル合意事例、CMI 降順で選択) で構成された。優先度 B は Gemini 単独 HIGH 事例の中で CMI が最も高い 8 文書 (CMI 範囲 : 25.8-38.0) で構成され、単一モデルの不一致にもかかわらず語彙シグナル密度が比較的高い事例を表す。優先度 C は Gemini 単独 HIGH 事例の中で CMI が最も低い 5 文書 (CMI 範囲 : 0.0-10.0) で構成され、語彙シグナル密度がほぼゼロにもかかわらず Gemini が HIGH を付与した検出限界境界の事例を表す。なお、Gemini 2.5 Flash は Run 2-6 全体で文書の 86.4% に HIGH を付与するという系統的 HIGH 膨張バイアスを示した (human_label の 56.5% と比較) ; したがって優先度 C 事例は真の検

²Gemini の Run 1 はコーパスターゲットリストが確定する前に実施されており、部分的に重複する文書セット ($n = 213$ 、Run 2-6 と 200 文書を共有) を処理した。両モデルにわたる対称的な 5 回実行設計を維持するため、この Run は Section 4.3 で報告するすべての分析から除外する。

出困難よりもこの分布バイアスを部分的に反映している可能性がある。定性的分析は構造的不一致タイプを特定するために設計されており、優先度 C 事例の価値は Gemini の HIGH 付与自体が正確だったかではなく、以下に記述する不一致類型に独自の構造的パターンを貢献するかどうかにある。

25 文書それぞれを著者が v0.7.1 注釈基準を参照しながら再読した。各事例について著者は記録した：(1) HIGH の付与を根拠づける v0.7.1 の主要条件 (H-1 から H-4)；(2) 自動 CMI が HIGH 閾値に達するのを妨げた語彙的または構造的特徴；(3) 著者の元の human_label が HIGH ではなく MEDIUM であった構造的な理由。この再読は、開放型帰納的コーディングではなく——偽陰性問題の先行理論的分析から導出された五つの構造的タイプという事前規定の分析枠組みに対して実施された。理論的飽和に達するまで定性的コーディングを継続した；最初の 20 事例以降に新しい構造的タイプは現れず、25 文書サンプルが主要な不一致パターンを捕捉するのに十分であることが示唆された。³ 定性的コーディングは著者のみが実施した；単一評定者定性的分析の限界は Section 5.3 で議論する。

五つの構造的タイプはそれぞれ、操作と親和的なシグナルの存在にもかかわらず、テキスト内の利用可能な言語的証拠が v0.7.1 基準のもとでの HIGH 分類を確認するには不十分であるという共通の基底構造を持つ。タイプは、この証拠的ギャップが生み出される具体的メカニズムにおいて異なる。

五つの構造的タイプは：(1) テキスト内での確認された証拠の不在（誘導経路は存在するが最終的な行動標的が明示されていない）；(2) 組織的または文脈的知識の意図的除外（HIGH の分類を確認するテキスト外情報が v0.7.1 基準に従って意図的に注釈決定から除外された）；(3) 正当な商業的実践との区別困難（言語的構造が操作的と非操作的な商業的コミュニケーション双方と整合する）；(4) 複数テキストにわたる連続的誘導構造の中の単一エピソードとしての文書（操作的構造は個別文書内ではなく連続全体を通じてのみ完全に視認可能である）；(5) 強制または強迫シグナルの不在（誘導は明示的な脅威または緊迫感語彙なしに肯定的フレーミングを通じて機能する）。

4. 初期較正と探索的検証

4.1 研究デザイン

本較正は明示的に予備的範囲のものである。較正コーパスは、mass_audit.py パイプラインを用いた URL 自動スクレイピングと、ソーシャルメディアコンテンツに対する OCR ベースのスクリーンショット処理による手動収集を組み合わせた 217 文書から構成される。217 文書のうち 9 文書は、JavaScript レンダリングされたコンテンツの取得不能または日本語パイプラインによる英語ソースの除外により、CMI スコア 0.0 を返し、有効 CMI スコアを持つ文書は 208 文書となった（CMI > 0）——この構造的限界は Section 5.4 に記録されている。除外された 9 文書のうち 1 文書は human_label = HIGH を付与されており、この文書は取得失敗事例としてコーパスに保持されるが、Section 4.3 で報告する Precision/Recall 分析における偽陰性としては計上しない。

グラウンドトゥールズ分類は、著者による単一評定者専門家判断を通じて決定された。著者の臨床心理学訓練と 20 年間の教育実践経験に基づき、暫定的な構造化ループブリックが適用された。このループブリックは文献においてすでに確立された二つの理論的枠組みを参照している：Ross (2014) による強制的コミュニケーションの三基準モデル（絶対的権威・強制的説得技法・搾取的フレーミング）と、Janis (1972) の集団思考症状プロファイルである。専門家判断は文書レベルで適用され、これらの理論的基準と著者の臨床心理学訓練（修士、愛知学院大学、2012 年）を統合した。初期スキャン段階の完了後、

³五つの構造的タイプは Sections 5.7 および 5.8 の偽陰性問題の先行理論的分析を通じて確立され、25 文書サンプルへの仮説駆動型コーディング枠組みとして適用された。再読は、これらのタイプをゼロから生成するためではなく、実証的事例に対してこれらのタイプを検証・精緻化するために機能した。20 事例以降に新しいタイプが現れなかったことは、枠組みの実証的妥当性を支持する証拠として扱われ、演繹的証明としてではない。

注釈基準をバージョン 0.7.1 に統合し、コーパス全体を v0.7.1 に基づくゼロベースラインから再注釈した。

4.2 コーパス記述

217 文書コーパスは、標準モード ($\text{HIGH} \geq 41$) の下で以下の分布を示す。有効 CMI スコアを持つ 208 文書に基づく：高リスク文書 ($n=44$, $\text{CMI} \geq 41$)、中リスク文書 ($n=37$, $35 \leq \text{CMI} < 41$)、低リスク文書 ($n=127$, $\text{CMI} < 35$)、 $\text{CMI} = 0.0$ を返した 9 文書は分類から除外。この分布は、現在の語彙アーキテクチャが高精度モード ($\text{HIGH} \geq 60$, $n=6$) よりも広い範囲で HIGH 分類を達成するという構造的知見を反映しており、標準モードはスクリーニング感度を最適化するように設計されている。

ジャンル分布には以下が含まれる：政府・機関文書 (LOW ベースライン)、商業的操作コンテンツ (投資スキーム・MLM・ダイエット/健康商品)、スピリチュアル・疑似科学的コンテンツ、政党メディア (国内および国際的国家系メディア)、カルト・宗教組織コンテンツ、法律情報アカウント、金融アドバイスコンテンツ、書籍形式テキスト (4 タイトル 22 章；カリスマ的起業家および教育批評ジャンル)。書籍形式サブセットは、表面的肯定語彙による偽陰性パターンのクロスジャンル再現事例として Section 5.8 で個別分析する。

4.3 結果

CMI スコアはコーパス全 217 文書にわたって算出された。このうち 9 文書が $\text{CMI} = 0.0$ を返したため、以下の要約統計からは除外する。当該 9 文書はすべて文書化事例 (取得失敗または日本語パイプラインによる英語ソース除外) としてコーパスに保持する。要約統計は有効 CMI スコアを持つ 208 文書 ($\text{CMI} > 0$) について報告する。

Table 1. 自動分類レベル別 CMI 要約統計

レベル	n	平均	SD	最小	最大
HIGH	44	49.0	6.6	41.3	67.6
MEDIUM	37	37.3	1.8	35.0	40.9
LOW	127	21.7	8.5	2.6	34.9
全体	208	30.3	13.5	2.6	67.6

有効文書全体の CMI 中央値：30.6。

注釈基準をバージョン 0.7.1 に統合した後、著者はコーパス全 217 文書をゼロベースラインから再注釈した。v0.7.1 のもとで、human_label 分布は $\text{HIGH} = 123$ 、 $\text{MEDIUM} = 79$ 、 $\text{LOW} = 15$ となった。HIGH 評定の 123 文書のうち 1 文書は $\text{CMI} = 0.0$ を返したため Precision/Recall 分析から除外し (Section 4.1 参照)、有効 HIGH 分母は 122 文書となる。以下に報告する性能指標はこの再注釈に基づく。

正確一致率 (自動レベルと v0.7.1 human_label の一致、有効 $n = 208$)：29.8% (62/208)。一段階以内の一致：76.0% (158/208)。標準モードにおける HIGH リスクの二値分類 ($\text{HIGH} \geq 41$)：Precision = 97.7% (TP = 43, FP = 1)、Recall = 35.2% (FN = 79)、F1 = 51.8。高精度モード ($\text{HIGH} \geq 60$)：Precision = 100.0% (TP = 6, FP = 0)、Recall = 4.9% (FN = 116)。高い Precision と控えめな Recall を合わせて解釈すると、語彙アーキテクチャは v0.7.1 のもとで高特異度・低感度のスクリーニングフィルターとして機能することが示される：HIGH フラグが立てられた文書はほぼ例外なく人間判断で HIGH と確認されるが、人間が HIGH と評定した文書の相当部分が語彙的閾値を下回る。Precision と Recall の定量的乖離は、Section 7.2 で述べる Phase 2 構造的検出層の直接的な実証的動機を提供する。

Section 3.7 で詳述した LLM パイロット注釈実験の信頼性結果について、Claude の 5 回実行 (Run 1–5, $n = 217$) では κ が 0.206 から 0.258 の範囲で変動し ($M = 0.231$, $SD = 0.020$)、Gemini の 5 回

実行 (Run 2-6、n = 213) では κ が 0.068 から 0.129 の範囲で変動した ($M = 0.103$ 、 $SD = 0.026$)。Landis and Koch (1977) の基準では両モデルとも「Slight (ほぼ偶然)」から「Fair (やや一致)」の範囲に位置し、 $\kappa \geq 0.60$ 受容閾値を下回る。この予備結果の解釈は Section 5.3 で展開する。

4.4 不一致の分析

三つのカテゴリの不一致が特定された。

第一は、テキスト取得上の限界に関するものである。BeautifulSoup ベースのスクレイピングがアクセスできない JavaScript レンダリングされた動的コンテンツにより、 $CMI = 0.0$ を返した文書が生じた。

第二は、政治的フレーミングコンテンツのスカラー過小検出に関するものである。国家系国際メディアおよび国内政党メディアは、EnemyFrame および FearRisk の最大密度での活性化を示しながらも、スカラー CMI スコアでは LOW を返した。これは現在のスカラー集約アーキテクチャの構造的限界を反映している。

第三は、風刺的模倣に関するものである。操作的ニュース構造を意図的に模倣した風刺的コンテンツ (虚構新聞) は、専門家の LOW 評定と対比して高い CMI スコアを示した。

4.5 辞書較正への示唆

予備的結果は、R8 の現行語彙辞書が商業的フレーミングの操作に対して感度を持つ一方、逸話的操作・スピリチュアルフレーミングによる権威・風刺的模倣を捕捉するためには拡張が必要であることを示している。

5. 現在の限界

5.1 表層的語彙照合

現在の実装は表層的語彙照合のみに依拠しており、文脈的曖昧性解消・語彙的変形・談話レベルの操作構造を考慮しない。この設計選択から三つの具体的な帰結が生じる。第一に、同一の表層形が文脈に応じて異なる意味機能を持つ場合に、システムはこれを区別できない。第二に、言い換えと語彙的代替により、操作親和的なコンテンツが検出を完全に回避できる。第三に、採点アーキテクチャは文書全体にわたる語彙密度を測定するため、局所的に集中した高重大度シグナルが長文テキストにおいて系統的に希釈される (実証的示例については Section 5.10 参照)。

これらの制約が持つ偽陽性と偽陰性の含意は、較正コーパスにおいて実証的に観察されている。AI サイコファンシーに関する著者自身の分析的エッセイ (コーパス ID: note223) は、偽陽性リスクの文書化事例を提供する。カテゴリレベル分析では、LogicalRisk (密度 1.0)・AuthorityRisk (密度 1.0)・StatisticalRisk (密度 1.0) が飽和に達し、EmotionalRisk (0.462)・FearRisk (0.74)・HypeRisk (0.74) も活性化していた——これらは操作的意図ではなく分析的散文の論証的・批判的レジスターに構造的に帰属するパターンである。このことは、システムが修辭的構造としての論理的論拠と操作技法としての論理的誘導とを区別できないことを示す。

これらの限界は辞書拡張のみでは解決不可能である。語彙のみの検出上限は、バージョン 10 から 16 にわたる辞書開発の反復プロセスを通じて実証的に確定された。

5.2 言語スコープ

現在の実装は日本語に特化している。すべての辞書・正規化手順・検証コーパスは日本語テキストのために構築されており、理論的枠組みも実質的に日本の組織社会学と文化心理学に依拠している。

この制約は技術的限界ではなく意図的なスコープ設定上の決定を反映している。英語および他の東アジア言語を含む他言語への拡張は、対象言語文脈における妥当性の確認された注釈プロトコルと比較可能な理論的根拠の確立を前提とした、より長期的な研究方向性である。

5.3 校正コーパスの限界

現在の校正コーパスは確定的な統計的推論には不十分である。システムの著者が唯一の人間注釈者であることは重大なバイアス源を構成する。注釈基準をバージョン 0.7.1 に統合した後、著者はコーパス全 217 文書をゼロベースラインから再注釈した。この再注釈が Section 4.3 で報告した human_label 分布と Precision/Recall 数値を生成した。

さらに、コーパスには AI サイコファンシーを検討した著者自身による批評的エッセイ（コーパス ID：note223）が含まれる。この文書は著者側に操作的意図がないにもかかわらず自動 CMI スコア 50.5 (HIGH 分類) を生じ、v0.7.1 基準のもとで human_label = LOW が付与された。note223 は Section 4.3 で報告した標準モード HIGH 分類における唯一の偽陽性 (FP = 1) を構成する。この事例は意図未解決分類の文書化事例としてコーパスに保持される：語彙密度のみでは操作的言説の批判的分析と操作的言説自体を区別できない——両者は類似した語彙分布を再現しうるためである。この唯一の FP が 217 文書コーパス全体にわたって持続することは、辞書精緻化によって対処できる校正上の欠損ではなく、テキスト内部採点アーキテクチャの構造的限界を表している。

AuthorityHalo および NormativeInduction シグナルのスコープに関する関連する構造的知見がある。これらのパターンは未知または詐欺的な送信者からのテキストに限定されない：確立した社会的信用性を持つ公的に認知された起業家や創作者によって執筆されたテキストもこれらのパターンを示す（例：著名な公人からのメンバーシップコミュニティコミュニケーション、本コーパスでは MEDIUM 評定）。この観察は、R8 が送信者の信用性や意図の代理指標としてではなく認知操作シグナルとして機能する言語構造を検出するという設計原則を強化する。したがって高い CMI スコアは詐欺的意図を確認も否定もしない；それは送信者の地位にかかわらず System 1 標的型言語パターンの存在を示す。この区別は展開文脈における MEDIUM 分類テキストの解釈に直接的な含意を持つ：高信用性送信者の MEDIUM スコアは未知送信者の HIGH スコアと同等の精査を要する可能性がある——語彙アーキテクチャは表面的肯定的権威フレーミングと無害な専門家コミュニケーションを区別できないためである。

Phase 2 は、信頼性指標として Cohen's κ を用いた最低二名の独立した人間評定者による正式な評定者間信頼性評価を確立する。 κ は以下のように算出される：

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

ここで P_o は観察された一致割合を、 P_e は偶然期待される一致割合を表す。受容可能な信頼性の基準として最低閾値 $\kappa \geq 0.60$ が採用される。これは Landis and Koch (1977) の基準と一致しており、 κ 値 0.41–0.60 を中程度、0.61–0.80 を実質的、0.81–1.00 をほぼ完全な一致として特徴づける。

Phase 2 評価 (Section 4.3 で報告) に先立って実施した LLM パイロット注釈実験では、Claude Sonnet 4.6 と著者の v0.7.1 human_label の間で Cohen's $\kappa = 0.231$ (M、Run 1–5、 $n = 217$)、Gemini 2.5 Flash との間で $\kappa = 0.103$ (M、Run 2–6、 $n = 213$) が得られた——いずれも Landis and Koch (1977) 基準で「Slight」から「Fair」の範囲であり、 $\kappa \geq 0.60$ 受容閾値を下回る。この予備結果は独立した人間評定者による正式な Phase 2 評価に代わるものではない；むしろ、v0.7.1 注釈基準——二段階認知誘導ア

ーキテクチャ（Section 5.7）と表面的肯定語彙操作（Section 5.8）の構造的読解を必要とする——が現在の汎用言語モデルでは再現不可能な判断負荷を課すことを示す。正式な κ 評価は独立した人間評定者によって実施される Phase 2 要件として残る。

5.4 デジタルメディア適用上の制約

URL 基盤の語彙分析のデジタルメディアへの適用は、階層的な構造的制約に直面する。技術的レベルでは、高リスクなウェブコンテンツの相当部分が JavaScript レンダリングを採用しており、直接的な HTML 抽出が妨げられる。URL 直接スキャンはテキスト変換スキャンに対して一貫して大幅に劣る（同一ページで CMI 10.0 対 44.7 を確認）。

JavaScript 問題を超えて、ソーシャルメディアコンテンツの構造的特性からより根本的な制約が生じる。X（旧 Twitter）のような短文投稿プラットフォームは質的に異なる課題を提示する。較正中に子ども殺人事件に関する X 投稿 5 件（コーパス ID：sn229–sn233）を OCR パイプライン経由でスキャンした。EnemyFrame および Propaganda カテゴリと一致する語彙を含むにもかかわらず、全 5 件が CMI LOW を返した。二つの失敗モードが特定された：140–80 文字テキストに対する密度計算の失敗、および OCR 誘発の文字レベル誤読による辞書照合の破損である。

最も根本的な限界は認識論的なものである。「公人の家族が特定の国籍または所属を持つ」といった事実基盤の偽情報——その虚偽性が語彙分析のみでは評価できない具体的な事実的主張——は、現在のシステムの検出スコープの範疇外に構造的に位置する。これは語彙パターン検出と事実検証の間の構造的境界を反映しており、辞書拡張によって解決できるものではない。

Phase 2 の設計優先事項には、テキスト長に基づく動的閾値調整（短文モード）と、採点前に複数の投稿を統合文書として処理するスレッドレベル集約が含まれる。

5.5 辞書構築方法論

現在の語彙辞書は、コーパスベースの帰納ではなく理論的推論と専門家判断を通じて構築された。バージョン 10 から 17 にわたる R8 辞書の反復の開発プロセスは、特定のジャンルに対する検出カバレッジを拡大した（v11–13 でスピリチュアル/疑似科学コンテンツ、v14–15 で政治的陰謀コンテンツ、v16 で削除脅迫型緊急パターン）。しかしこの拡張プロセスには構造的上限がある：最も洗練された操作コンテンツは辞書拡張にかかわらず MEDIUM 範囲に留まった——操作がいずれのリスクカテゴリにも現れない語彙を通じて機能するためである。

この反復的拡張プロセスは循環的検証のリスクをもたらす。したがって辞書拡張は精度改善戦略としてではなく、トランスフォーマーベースの文脈的分析への移行前における語彙検出上限の文書化として再定義される。バージョン 17 は、較正コーパスで代表されているジャンルに対して表層的語彙照合が達成できる現在の限界を表している。

5.6 理論的枠組みと実装手法の乖離

R8 は操作親和的な言語シグナルの密度を近似するオープンソースの透明な計測器である；表層的語彙パターンは操作的意図や効果を確立しない。本論文の他のすべての限界の根底にある構造的限界は明示的な言明に値する。Section 2 で提示した理論的枠組みは、認知心理学（Kahneman, 2011）・社会心理学（Janis, 1972; Milgram, 1974; Zimbardo, 2007）・日本の組織社会学（Nakane, 1967; Yamamoto, 1977）を踏まえ、認知操作を多層的現象として特徴づける。R8 は System 1 認知処理（Kahneman, 2011）を標的とする言語シグナルの検出システムとして理論的に位置づけられている。

実装手法——表層的語彙密度分析——は質的に異なる記述レベルで機能する。どれほど辞書を拡張しても、単語を数えることと認知的効果を測定することの間の乖離は埋まらない。

この乖離が求めるのは、理論的主張における明示的な抑制である。本論文は R8 を、CMI スコアが認知操作を直接測定するという主張としてではなく、操作親和的シグナル密度を近似する語彙スクリーニングツールとして提示する。Section 2 の理論的枠組みはカテゴリ設計を動機づけ解釈的文脈を提供するものとして読まれるべきであり、CMI スコアが理論的構成概念を直接測定するという主張としてではない。この区別は Section 5.7 から 5.10 で文書化された限界に対して特に重要である。

5.7 著者の意図と語彙的推論の限界

操作的テキストと非操作的テキストの間の最も根本的な区別——著者の意図——は、語彙的証拠のみからは解決不可能である。☒正コーパスの分析は、この問題の二つの異なる構造的側面を特定する。

第一の側面は、意図なき操作的コミュニケーターの問題である。これは操作的に機能するテキストを産出するが、操作的意図を持たない著者の事例を含む：カリスマ的なコーチング・宗教的指導者・自己啓発の著者・AI システム。これらの著者は、読者において System 1 活性化パターンと一致する語彙密度を産出しながら、製品・信仰・個人的成長について誠実に伝達している。較正コーパスはこのカテゴリの複数の事例を含む：著名な起業家・スピリチュアルな実践者・誠実な宗教的指導者からのテキストが、詐欺的動機から産出されたテキストと区別できない CMI プロファイルを産出する。

第二の側面は、慣習的高リスク言語の問題である。特定の言語慣習は、それ自体は操作的意図を持たない文脈においてもリスクカテゴリと一致する語彙を産出する：緊急医療コミュニケーション (FearRisk)・学術的権威引用 (AuthorityRisk)・統計的報告 (StatisticalRisk)・法的免責事項 (DisclaimerExploit)。これらのジャンルは CMI スコアを産出するが、それらが操作的意図を示すとは言えない。

これらの限界は R8 の語彙アーキテクチャの外部から解決することはできない。語彙的証拠は著者の意図を検出できない；語彙的証拠から推論できるのは、テキストが System 1 を活性化させる可能性のある言語構造を含むかどうかという問いに対する答えのみである。

5.8 表面的肯定語彙と系統的偽陰性

最も実証的に重要な限界は、「表面的肯定語彙」を通じて機能する操作コンテンツの系統的過小検出である。カリスマ的自己啓発言説のサブジャンル——カリスマ的コーチング・スピリチュアルマーケティング・ライフスタイルアントレプレナーシップ——は、R8 の語彙カテゴリのいずれにも現れない肯定的フレーミングを採用する。これらのテキストは、恐怖・緊迫感・外敵フレーミング・明示的な統計的操作に依拠するのではなく、EMPOWERMENT と帰属を通じて機能する：感謝・個人的成長・コミュニティ・可能性の語彙をすべての節にわたって採用し、システム読者に対して EmotionalRisk 密度を最小化しながら LogicalRisk 密度を最大化するプロファイルを産出する。

この表面的肯定語彙パターンは、オンライン自己啓発コンテンツの分析を通じて確認された。渡辺コーパス (コーパス ID: note_011–note_016、note_021) はこの偽陰性クラスを例証する：著者が 2010–11 年に活動した日本のビジネスコーチのテキストで、7 文書すべてが human_label HIGH を受けたが (多数の独立した報告に記録された詐欺的行為を実証する後続の法的証拠に基づく)、自動 CMI スコアは 3.6 から 25.4 の範囲 (全 LOW 分類) であった。カテゴリベクトル分析は LogicalRisk 飽和 (0.74–1.0) と近ゼロ EmotionalRisk (0.0–0.094) を示す——このプロファイルは Section 5.7 が特定した意図なき操作的コミュニケーターパターンと構造的に同一であるが、この事例では詐欺的意図の外部証拠が確立されている。この不一致は、語彙のみの採点アーキテクチャが検出できない操作モードが存在することを示す：論理的誘導と慣習的語彙のみを通じて機能する操作——感情的・緊迫感ベースのシグナルなしに。

この偽陰性パターンのクロスジャンル再現が書籍形式コーパスで特定された。カリスマ的起業家テキストの 7 章 (与沢翼、2013 年、『秒速で 1 億円稼ぐ条件』、フォレスト出版；コーパス ID: book001_ch01–ch07) を同一パイプラインで分析した。全 7 章が HIGH の human_label 付与を受けた；自動 CMI ス

コアは 18.6 から 45.5 の範囲であり、7 章中 5 章が LOW 分類された。LogicalRisk は全章で飽和に達し (0.74–1.0)、AbsolutistWords は 2 章 (ch03、ch07) で上限 (1.0) に達したが、EmotionalRisk は全体を通じてゼロ近傍 (0.0–0.139) に留まった。このプロファイルは、Phase 1 ウェブコーパス較正で特定されたカリスマ的起業家テキスト (渡辺コーパス、2010–2011 年) と構造的に同一である：LogicalRisk 飽和が EmotionalRisk ほぼゼロと共に、専門家の HIGH 評価にもかかわらず系統的過小検出を生じる。2010 年代初頭にまたがる出版期間を超えたクロスコーパス再現は、この偽陰性パターンが個別の著者スタイルの産物ではなくカリスマ的起業家言説の安定した構造的特徴を反映することを示唆する。このパターンは表面的非否定語彙操作の通時的再現——語彙辞書拡張がいかなる構造的解決策も提供できない系統的偽陰性クラス——を構成する。

5.9 重大度重み付けの限界

現在の採点アーキテクチャは重大度重み付けなしに語彙密度を集約する。カテゴリ内では、すべての照合用語が等しく寄与する——検出された操作技法の潜在的な害の重大度にかかわらず。同様に、単一の高重大度シグナル (例：自傷行為への明示的な勧誘) が多数の低重大度シグナルと等価に扱われる可能性がある。

この限界は Phase 2 の設計変更として特定されている：辞書用語に重大度重みを割り当て、採点関数を語彙密度と重大度の関数として再定義する。しかしこの変更は実証的な検証——最終的な実証的妥当性と使用法との照合によって検証される重大度の専門家評価——を必要とし、それは Phase 2 のより大きな独立注釈コーパスの要件内に含まれる。

5.10 短文テキスト適用上の制約

CMI 密度計算は適切なカウントのために実質的なテキスト長を必要とする。短文テキスト (140 文字未満のソーシャルメディア投稿、短いチャットメッセージ) は密度採点において構造的に不利である：同じ操作語彙がより長いテキストよりも低い CMI スコアを産出する——その密度が等しい期待有害性を持ちうるにもかかわらず。

この限界は特に、ソーシャルメディアを通じた操作キャンペーン——短文メッセージの多量送信によって機能する——を対象とする際に重要である。この問題に対処するためのアーキテクチャの変更が確認されている (スレッドレベル集約・動的閾値調整) が、これらは Section 4.4 で記録された技術的収集問題と組み合わせ、Phase 1 較正のスコープにおいてソーシャルメディアコンテンツを実質的に分析できないものとしている。

6. 考察

6.1 スクリーニングツールとしての R8：有用性と認識された限界

Phase 1 較正結果は、R8 の語彙アーキテクチャの能力と限界の両方を示す。97.7% の Precision は、自動 HIGH フラグが立てられた文書が人間の専門家判断によって確認されることをほぼ確実にする：HIGH 分類される文書は人間の評価者が HIGH と確認することがほぼ確実である。しかし 35.2% の Recall は、人間が HIGH と評価した文書の三分の二以上が語彙的閾値を超えないことを意味する。

v0.7.1 のもとでの Recall 35.2% という数値は、語彙的性能の劣化ではなく注釈参照の実質的変化を反映している。v0.7.1 のもとで、基準が表面的肯定語彙と二段階認知誘導を通じて機能する構造的な操作テキストに対してより包括的になるにつれ、human_label HIGH セットが拡大した——Sections 5.7 およ

び 5.8 で文書化されたパターンである。語彙アーキテクチャはこれらのパターンを検出できないため、人間 HIGH 文書の増加は語彙的 Recall の対応する向上なしに偽陰性カウントを拡大した。この定量的変化は表面的肯定語彙偽陰性限界（Section 5.8）を直接的に実証し、Phase 2 構造的パターン検出を必要な次のアーキテクチャ層として位置づける論拠を強化する。

R8 の主要なスクリーニング用途——大量のテキストをより精密な調査のためにフラグを立てること——に対して、高 Precision・低 Recall のプロファイルは許容可能なトレードオフを表す：フラグが立てられたテキストは人間のレビューを正当化し、検出されないテキストは語彙的シグナルを欠く。後者が偽陰性を構成するか語彙的に洗練された操作を構成するかの区別は、Section 5.8 で詳述した構造的な第二検出層なしには解決できない。

6.2 CMI スコアとカテゴリベクトルプロファイル

スカラー CMI スコアは文書レベルのリスクの概要を提供するが、カテゴリベクトルプロファイル——12 カテゴリにわたる個別の密度値のセット——はより豊かな診断情報を提供する。政治的フレーミングコンテンツは EnemyFrame・PropagandaRisk・FearRisk の同時活性化を示し、スカラー CMI が閾値以下であっても——これは複数カテゴリにわたるリスクの識別可能なシグネチャを構成する。カリスマ的起業家テキストは LogicalRisk 飽和と近ゼロ EmotionalRisk を示し——これが偽陰性クラスの中核的シグネチャである。これらのパターンは、ベクトルレベルでの解釈がスカラー CMI 採点を単独で超える情報を提供することを示す。

6.3 表面的肯定語彙と偽陰性問題

Section 5.8 で文書化された偽陰性パターンは Phase 1 の最も重要な診断的知見を構成し、Phase 2 のアーキテクチャ的優先事項を直接的に動機づける。このパターンは単に語彙カバレッジの問題ではない——肯定的フレーミングに対応する語彙を追加することは偽陰性の問題を解決しない：肯定的語彙の存在は操作の非存在を示さない。問題は、特定の操作パターンが語彙的指標として語彙密度ではなく語彙シーケンス——言い換えれば、どの用語がどの文脈において隣接して出現するか——を通じて機能するという構造的なものである。この問題の解決は Phase 2 で説明する構造的パターン検出の第二層を必要とする。

6.4 短文ソーシャルメディアコンテンツ

操作コンテンツはますます短形式・プラットフォームに適したフォーマットで配信されており、表層的語彙スクリーニングにとっての構造的課題となっている（Section 5.10）。sn229–sn233 の事例で実証されたように、短文 X 投稿の密度採点は意味のある結果を産出しない——すべて技術的かつ構造的な理由から。この制限は Section 7.2 で概説する Phase 2 のスレッドレベル集約戦略によって部分的に対処できる：単一の投稿ではなく投稿のスレッドを分析することで、密度問題を緩和しながらソーシャルメディアコンテンツへの適用を可能にする。

6.5 循環的妥当性と独立した検証の必要性

現在の較正設計における最も重要な方法論的限界は単一評定者問題である：著者は注釈基準を設計し、注釈を実施し、性能指標を解釈した。この三重の役割は独立した評価を構造的に排除し、循環的妥当性のリスクを生み出す——すなわち、注釈基準が自動採点と整合するように暗黙的に較正される可能性である。

この問題の解決は Phase 2 の基盤的要件である：新しい評定者が注釈基準を独立して適用し、著者が

システムを正当化するために較正されたパターンを一致として計数できないことを確保する。独立した人間注釈による Cohen's $\kappa \geq 0.60$ という最低基準は、この検証要件を操作化する。現在の LLM ベースのパイロット実験 (Claude: $\kappa = 0.231$; Gemini: $\kappa = 0.103$) はこの要件を満たさない——LLM は独立した評定者ではなく、v0.7.1 基準のもとで人間の判断を再現できないことが確認されている。

7. 今後の課題

7.1 Phase 2: 検証コーパス拡張と評定者間信頼性

較正コーパスの拡張と評定者間信頼性の確立が直近の実証的優先事項である。Phase 2 コーパス設計は以下を通じて現在の限界に対処する: (1) JavaScript レンダリングのために自動収集が失敗する HIGH リスク文書の手動収集; (2) 真正な肯定的テキスト (行政文書・医療同意書) の対照コーパスの追加; (3) ソーシャルメディアコンテンツ (SNS) の包含; (4) Cohen's κ 測定 ($\kappa \geq 0.60$; Landis & Koch, 1977) を伴う最低二名の評定者による独立した注釈。 κ 閾値 0.60 は、コーパス拡張が進む前の受容可能な信頼性の最低基準として採用される。評定者間訓練と注釈プロトコルは Phase 2 注釈サイクルに先立って標準化される。Phase 2 構造的検出層の実装後 (Section 7.2)、更新された検出基準に対する LLM ベース注釈性能の再評価が計画されている; 現在の $\kappa = 0.231$ (Claude Sonnet 4.6) および $\kappa = 0.103$ (Gemini 2.5 Flash) のベースライン値は、構造的パターン検出が人間と LLM 注釈者の間の判断負荷ギャップを縮小するかどうかを評価するための基準点として機能する。

Phase 2 は、コーパス拡張前の必要条件として注釈基準の統合と Cohen's κ 信頼性測定を伴う最低二名の独立した評定者を確立する。Section 3.7 および 4.3 で報告した LLM パイロット注釈実験 (Claude Sonnet 4.6: $\kappa = 0.231$; Gemini 2.5 Flash: $\kappa = 0.103$; 各 5 回実行) は、この独立性要件が LLM ベース注釈によって回避できないことを確認する: 現在の汎用言語モデルは v0.7.1 が要求する構造的読解を再現できないため、Phase 2 信頼性評価における人間評定者の代替となることができない。独立した人間注釈による最低二名の評定者は、Phase 2 コーパス拡張が進む前の交渉不可能な前提条件として残る。

7.2 Phase 2: ベクトルプロファイル開発と構造的パターン検出

Phase 1 較正は、現在の語彙アーキテクチャが語彙密度のみから捕捉できない操作パターンを記録した。この診断的知見が Phase 2 の中心的な開発優先事項を動機づける: 構造的パターン検出の第二層——語彙密度照合を超えた操作パターン認識——である。

特定された Phase 2 設計ターゲット: (1) 逐次誘導パターン検出: 「自己達成のナラティブ → 推薦への誘導」チェーンの検出——操作がメッセージシーケンスを通じて機能する場合; (2) 合意誘導終端検出: 「多くの人が〜」「みんな〜」パターンのような文末合意誘導シグナル; (3) 数値カスケード検出: テキスト全体にわたって蓄積する無引用数値主張のセット; (4) 問題フレーミング → 自己解決者シーケンス: 問題提示に著者の推薦が続く構造; (5) 希少性・緊急性提示: 時間制約・数量制約シグナルの検出 (ScarcityRisk 独立カテゴリとして提案)。これらのターゲットは Cialdini (1984)・Milgram (1963)・Janis (1972) の理論的フレームワークに根拠を持ち、Phase 1 カテゴリベクトル分析を通じて経験的に特定された操作パターンを反映する。

7.3 Phase 2: トランスフォーマーベースの文脈的分析

現在の語彙アーキテクチャが不可避免的に直面する文脈的曖昧性の問題は、Phase 2 の技術的研究優先事項として文脈的シグナル重みづけのためのトランスフォーマーベースの埋め込みの探索を促す。この

方向は同一の解釈可能性の問題を再現する：注意重みと埋め込み空間は人間が監査可能な説明を産出しない。したがってトランスフォーマーベースのアーキテクチャは解釈可能な語彙採点の代替としてではなく、特定の検出困難事例——曖昧な権威参照・文脈依存的な感情的フレーミング——に対する補完的分析層として探索される。

7.4 Phase 2 拡張：非線形検出モデルとマルチステージアーキテクチャに向けて

現在の CMI は語彙カテゴリスコアの線形重み付き合計として算出される。このアーキテクチャは各シグナルタイプの説得リスク寄与が加算的かつ独立であると仮定する——Phase 1 の観察が実証的に不完全であることを示唆する仮定である。

二つの非線形効果が Phase 2 拡張研究優先事項として特定される。第一は肯定的と否定的感情シグナルの間の交互作用効果である。高密度肯定的感情語彙 (EmotionalRisk) と高密度否定的感情語彙 (FearRisk) を組み合わせるテキストは線形スコア集約の予測を超える説得効果を産出する可能性があることが理論的に仮説される——Kahneman (2011) の否定性優勢の知見と一致する：否定的シグナルは同等の大きさの肯定的シグナルよりも高い優先度で処理されるため、連続した肯定-否定構造は相殺ではなく増幅を示す。

第二はマルチシグナル組み合わせにおける閾値効果である。Phase 1 較正の観察は、操作親和的シグナルがその全範囲にわたって比例した効果を産出しないが、閾値挙動を示すという仮説と一致する：シグナル密度閾値以下では効果は副線形（弱いまたは不在）；閾値を超えると効果は超線形（急速に増幅）になる。

この閾値構造の候補となる数学的形式化はシグモイド変換である：

$$CMI_{\text{nonlinear}} = \frac{1}{1 + e^{-k(CMI_{\text{linear}} - \theta)}}$$

ここで θ は個人の応答閾値を、 k は遷移の急峻さを制御する傾斜パラメータを表す。この形式化は Phase 3 実証調査の理論的枠組みとして提案される。単一評定者注釈を持つ 208 文書（有効 CMI > 0）の現在のコーパスは θ と k のパラメータを推定するには不十分であり、行動的アウトカム測定値（コンプライアンス率・金銭的損失・勧誘成功）の不在はこの段階では閾値モデルの実証的検証を不可能にする。この提案は実装されたコンポーネントではなく研究方向として提示される。

この理論的枠組みから導かれるマルチステージ検出アーキテクチャは以下のように構造化される。Phase 1 語彙スクリーニング（現在の実装）は第一段階フィルターとして機能し、CMI 35 以下の文書をさらなる処理から効率的に除外しながら、MEDIUM・HIGH 文書——および特定の共起パターンを持つ LOW 文書——を第二段階分析に向ける。Phase 2 構造的検出は未通過サブセットに共起パターン重み付け・段落シーケンス分析・ScarcityRisk の組み合わせ採点を適用する。Phase 3 の文脈的・行動的モデリングは、行動的アウトカムデータが利用可能になった場合に、トランスフォーマーベースの曖昧性解消・読者脆弱性プロファイリング・実証的閾値推定を統合する。このステージ構造のアーキテクチャは各フェーズでの検出効用を最大化しながら各分析層の限界について透明性を維持するように設計されている。

上記で導入された閾値モデルはまた、補完的構成概念の概念的基盤を提供する：認知脆弱性指数 (Cognitive Vulnerability Index, CVI)。CMI がテキストの操作親和的シグナル密度——送信者の特性——を定量化するのに対し、CVI は CMI シグナルが行動的效果を産出する時と場合を決定する閾値パラメータ θ として読者の認知的脆弱性を定量化する。CVI の理論的根拠は Cialdini (1984) の実証的観察——一貫性ベースの説得に対する感受性は年齢とともに増加する (p. 177) ——、Milgram (1974) の権威への服従を個人差変数として文書化した研究、および Altemeyer (1981) の右翼権威主義 (RWA) 尺度から直接導出される。RWA 尺度は権威への従順・慣習主義・外集団への敵意という傾向を、R8 の AuthorityRisk・AbsolutistWords・EnemyFrame カテゴリに構造的に対応する測定可能な個人差として

特定する。CVI の完全な操作化は現在の研究の範囲を超えており、Phase 2 実証的基盤に依存する開発を持つ Phase 3 理論的標的として提案される。

Phase 2 はまた、希少性シグナルの専用検出カテゴリ (ScarcityRisk) としての独立した操作化を調査する。現在の実装では、希少性と親和的な語彙は FearRisk・AbsolutistWords・ClickbaitRisk にわたって統一された検出アーキテクチャなしに分散している。Brock (1968) の商品理論と Brehm (1966) の心理的リアクタンス理論は、希少性シグナリングを独立した検出を正当化する構造的に異なる操作メカニズムとして扱う理論的根拠を提供する。ScarcityRisk 操作化のための五つの語彙サブタイプが提案される：時間的希少性 (「本日限り」「締め切り」)、数量的希少性 (「残り 3 つ」「50 名限定」)、情動的希少性 (「一部の人だけが知る」「一般非公開」)、関係的希少性 (「あなただけに」「特別に選ばれた」)、機会的希少性 (「このチャンスは二度と来ない」)。重要なことに、Phase 1 較正の観察は、これらのサブタイプが高リスクテキストにおいて単独で出現することはまれであり；むしろ、線形スコア集約が捕捉する範囲を超えた増幅された説得効果を生じる組み合わせパターンで共起することを示している (Fromkin & Brock, 1971)。Phase 2 は、ScarcityRisk サブタイプ組み合わせの重み付き共起採点を現在の語彙アーキテクチャ内でこれらの交互作用効果を近似するアプローチとして調査する。

さらに、マルチベクトル操作の方向性の概念が重要な将来の研究方向として浮上する。現在の R8 アーキテクチャは外部の聴衆に向けられたテキスト——いわゆる外向き操作ベクトル——を対象とする。しかし組織的・制度的テキストはしばしば複数の聴衆次元にわたって同時に機能する：外部に向けては公衆やメディアへ、内部に向けては組織メンバーへ、そして自己正当化のメカニズムとしてテキスト著者自身へと反射的に。Festinger (1957) の認知的不協和理論は、反証となる証拠に直面した組織の規範的枠組みの修辭的強化——内向き操作——が外部圧力が増加するにつれて解消ではなく強化されると予測する。この内向きベクトルパターンの実証的候補には、政府の危機対応テキスト・企業のインシデントコミュニケーション・制度的否定声明が含まれ、Phase 1 較正はこれらを系統的偽陰性カテゴリとして特定した：人間のラベルリスクが高くても自動 CMI が低い——お役所的な文体に宗教やビジネスジャンルの語彙がないため。ベクトル方向性の操作化——外向きの説得と内向きの自己正当化の区別——は Phase 2 のコーパス設計優先事項と Phase 3 のモデリングターゲットとして特定される。

7.5 Phase 3：多言語拡張

英語言語分析への拡張は、Phase 2 検証成果を待つ潜在的な方向である。

7.6 Phase 3：AI 生成テキスト分析

より長期的な研究方向は R8 の枠組みを AI 生成コミュニケーションの分析に拡張する。R8 の語彙カテゴリが AI 生成テキストのサイコファンシーバイアスパターンに対して感度を持つかどうかは、フレームワークの人間が著作したテキストに対する妥当性が Phase 2 で確立されるまで意味のある調査ができない開かれた実証的問いである。

7.7 Phase 3：マルチモーダル拡張

R8 の枠組みは音声・映像コンテンツに拡張可能である。技術的な実現可能性は確立されている：音声テキスト変換モデル (Whisper など) が R8 パイプラインの前段に置かれることで、音声または映像コンテンツを分析用のテキストストリームに変換する。この拡張の研究価値は、文章的操作と口頭的操作の間の検出感度の差を検討することにある——音声コンテンツは感情的韻律・ペーシング・語調変化のような語彙ツールが捕捉できない追加シグナルチャンネルを提供するためである。

8. 結論

R8 は日本語テキストにおける認知操作リスクを近似するための第一世代語彙フレームワークを提示する。12 の理論的根拠を持つリスクカテゴリを単一の合成指数——認知操作指数 (CMI) ——に操作化することにより、本システムはより詳細な精査を要するテキストを特定するための透明で再現可能かつスケーラブルなスクリーニングツールを提供する。本システムは操作的意図の確定的分類器としてではなく、人間判断を置き換えるのではなく補完する初期フラグとして明示的に位置づけられる。

R8 の理論的枠組みは、認知心理学 (Kahneman, 2011) ・ 社会心理学 (Janis, 1972; Milgram, 1974; Zimbardo, 2007) ・ 日本の組織社会学 (Tobe et al., 1991; Yamamoto, 1977; Nakane, 1967) を統合し、閾値下操作の臨床心理学的記述 (Symington, 1993) にも補足的に依拠する。本研究の新規な貢献は、これまで独立して発展してきた理論的領域を「System 1 認知処理を標的とする言語シグナル」という統合的視点の下に統合し、この統合を日本語テキストのための定量化可能な語彙的測定器として操作化したことにある。

Phase 1 較正は三つの主要な知見を特定した。第一に、CMI は EnemyFrame ・ Propaganda ・ FearRisk を同時に組み合わせる政治的フレーミングコンテンツに対して最高の検出性能を達成する。第二に、商業的操作コンテンツは表面的肯定語彙を通じて HIGH 分類を系統的に回避し、Phase 1 の中心的診断的知見を確立する。第三に、較正は語彙密度採点が高度な操作に対して系統的偽陰性を、論証的分析的散文に対して系統的偽陽性を産出することを確認し、語彙のみのアプローチの実証的天井を確立した。

現在の実装の限界は実質的であり、明示的に認識されている。これらの限界が Phase 2 研究課題を定義する：独立した評定者間注釈を伴う検証済みコーパス拡張；構造的操作パターンを標的とする第二検出層の開発；および偽陰性検出を可能にする対照コーパスの構築。

R8 は、それが第一近似であるという明示的な認識のもとでオープンソースソフトウェアとしてリリースされる。このリリースの価値は、透明で再現可能なベースラインを確立することにある——語彙検出の天井を構造的・意味的分析への移行前に文書化し、日本語認知操作研究を説得的・欺瞞的テキストの計算的検出に関するより広い国際的議論の中に位置づけるものとして。

参考文献

- Altemeyer, B. (1981). Right-wing authoritarianism. University of Manitoba Press.
- Arai, N. (2018). ロボットは東大に入れるか (改訂版) . 新曜社.
- Baumeister, R. F., & Leary, M. R. (1995). The need to belong: Desire for interpersonal attachments as a fundamental human motivation. *Psychological Bulletin*, 117(3), 497–529.
- Ben-Ghiat, R. (2020). Strongmen: Mussolini to the present. W. W. Norton.
- Brehm, J. W. (1966). A theory of psychological reactance. Academic Press.
- Brock, T. C. (1968). Implications of commodity theory for value change. In A. G. Greenwald, T. C. Brock, & T. M. Ostrom (Eds.), *Psychological foundations of attitudes* (pp. 243–75). Academic Press.
- Cialdini, R. B. (1984). *Influence: The psychology of persuasion*. Harper Business.
- Da San Martino, G., Yu, S., Barrón-Cedeño, A., Petrov, R., & Nakov, P. (2019). Fine-grained analysis of propaganda in news articles. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing* (pp. 5636–5646). Association for Computational Linguistics.
- Da San Martino, G., Barrón-Cedeño, A., Wachsmuth, H., Petrov, R., & Nakov, P. (2020). SemEval-2020

- task 11: Detection of propaganda techniques in news articles. In Proceedings of the Fourteenth Workshop on Semantic Evaluation (pp. 1377–1414). Association for Computational Linguistics.
- Eccles, J. S., & Wigfield, A. (2002). Motivational beliefs, values, and goals. *Annual Review of Psychology*, 53, 109–32.
- Festinger, L. (1957). *A theory of cognitive dissonance*. Stanford University Press.
- Fromkin, H. L., & Brock, T. C. (1971). A commodity theory analysis of persuasion. *Public Opinion Quarterly*, 35(3), 367–77.
- Granovetter, M. (1978). Threshold models of collective behavior. *American Journal of Sociology*, 83(6), 1420–443.
- Granovetter, M., & Soong, R. (1983). Threshold models of diffusion and collective behavior. *Journal of Mathematical Sociology*, 9(3), 165–79.
- Hathaway, S. R., & McKinley, J. C. (1943). *The Minnesota Multiphasic Personality Inventory*. University of Minnesota Press.
- Janis, I. L. (1972). *Victims of groupthink: A psychological study of foreign-policy decisions and fiascos*. Houghton Mifflin.
- Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–74.
- Milgram, S. (1963). Behavioral study of obedience. *Journal of Abnormal and Social Psychology*, 67(4), 371–78.
- Milgram, S. (1974). *Obedience to authority: An experimental view*. Harper & Row.
- Nakane, C. (1967). *タテ社会の人間関係*. 講談社.
- Pennebaker, J. W., Boyd, R. L., Jordan, K., & Blackburn, K. (2015). *The development and psychometric properties of LIWC2015*. University of Texas at Austin.
- Ross, R. A. (2014). *Cults inside out: How people get in and can get out*. CreateSpace.
- Sunstein, C. R. (2017). *#Republic: Divided democracy in the age of social media*. Princeton University Press.
- Symington, N. (1993). *Narcissism: A new theory*. Karnac Books.
- Tobe, R., Teramoto, Y., Kamata, S., Sugino, Y., Murai, T., & Nonaka, I. (1991). *失敗の本質*. ダイヤモンド社.
- Wang, Y., Yang, I., Hassanpour, S., & Vosoughi, S. (2024). MentalManip: A dataset for fine-grained analysis of mental manipulation in conversations. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Vol. 1, pp. 3747–3764). Association for Computational Linguistics.
- Yamamoto, S. (1977). *「空気」の研究*. 文藝春秋.
- Zimbardo, P. G. (2007). *The Lucifer effect: Understanding how good people turn evil*. Random House.

AI 開示

本論文は Claude (Anthropic) および Gemini (Google) の AI 支援のもとで開発・執筆された。概念的
枠組み・理論統合・研究方向性は著者のオリジナルである。AI ツールは草稿作成・翻訳・コード実装
支援に使用された。